trt-hackathon-2022

总述

本项目是trt-hackathon-2022 决赛项目, 将AnchorDETR从Pytorch模型转换到TensorRT并部署到NVIDIA A10 GPU上。

- 原始模型: Anchor DETR [pdf][code]
- 优化效果:精度上, 优化模型在COCO2017验证集上的mAP=43.934%, 相比原始精度, mAP下降0.329%。 性能上, 优化模型的latence=15.3353ms, throughtput=70.4344qps, 相比于TRT自动优化的原始模型, 提速 315.808%。

使用说明

准备环境

拉取docker镜像

```
sudo docker pull registry.cn-hangzhou.aliyuncs.com/trt2022/trt-8.4-ga
```

启动docker镜像,并挂在工作目录到/target下

```
sudo docker run -it --gpus all --name trt2022-final -v your_dir:/target
registry.cn-hangzhou.aliyuncs.com/trt2022/trt-8.4-ga:latest
```

前往官网下载TensorRT 8.4 GA for Linux x86_64 and CUDA 11.0, 11.1, 11.2, 11.3, 11.4, 11.5, 11.6 and 11.7 TAR Package, 将它解压在/usr/local下, 设置~/.bashrc中的环境变量

```
export PATH=/usr/local/TensorRT-8.4.1.5/bin:$PATH
export LD_LIBRARY_PATH=/usr/local/TensorRT-8.4.1.5/lib:$LD_LIBRARY_PATH
export LIBRARY_PATH=/usr/local/TensorRT-8.4.1.5/lib/stubs:$LIBRARY_PATH
```

修改完后激活环境变量

```
source ~/.bashrc
```

克隆仓库

```
git clone https://github.com/YukSing12/trt-hackathon-2022
cd trt-hackathon-2022
```

```
pip install -r requirements.txt
```

本代码在python=3.8.10, pytorch=1.9.1, torchvision=0.10.1环境下测试

准备数据

详见说明


运行命令

```
cd trt-hackathon-2022/onnx2trt
bash build_anchor_detr.sh
```

原始模型

模型简介

- 用途以及效果
- AnchorDETR是旷视提出的一种基于Transformer的目标检测器, 其引入了基于锚点的查询设计, 并设计了 行-列分离注意力的注意力变体, 使得AnchorDETR可以减少内存使用的同时, 提升了精度和减少了训练代数。
- 模型的整体结构如下



模型优化的难点

• 问题1:pytorch转onnx出现nan

```
array([[nan, nan, nan, ..., nan, nan, nan],
[nan, nan, nan, nan, nan, nan]], dtype=float32)
```

 解决1:AnchorDETR目录下, anchor_detr的forward输入的是一个NestedTensor, 需要将其拆分为两个 tensor输入(代码)

• 问题2:pytorch转onnx推理精度出现问题

```
IoU metric: bbox
 Average Precision
                     (AP) @[ IoU=0.50:0.95
                                              area=
                                                      all
                                                            maxDets=100 ] = 0.006
                     (AP) @[
 Average Precision
                             IoU=0.50
                                                      all
                                              area=
                                                            maxDets=100
                                                                         ] = 0.020
                     (AP) @[ IoU=0.75
 Average Precision
                                                      all
                                                            maxDets=100
                                                                         1 = 0.002
                                              area=
                     (AP) @[ IoU=0.50:0.95 |
 Average Precision
                                              area= small
                                                            maxDets=100
                                                                         1 = 0.005
                     (AP) @[
                             IoU=0.50:0.95
 Average Precision
                                              area=medium
                                                                         ] = 0.001
                                                            maxDets=100
 Average Precision
                     (AP) @[
                                                                         ] = 0.013
                             IoU=0.50:0.95
                                              area= large
                                                            maxDets=100
                     (AR) @[
                                                      all
 Average Recall
                             IoU=0.50:0.95
                                              area=
                                                             maxDets= 1
                                                                           = 0.020
                     (AR) @[ IOU=0.50:0.95
(AR) @[ IOU=0.50:0.95
 Average Recall
                                              area=
                                                      all
                                                             maxDets= 10
                                                                           = 0.039
 Average Recall
                                                      all
                                                            maxDets=100
                                                                           = 0.051
                                              area=
 Average Recall
                     (AR) @[ IoU=0.50:0.95
                                              area= small
                                                                         ] = 0.009
                                                            maxDets=100
                     (AR) @[
 Average Recall
                             IoU=0.50:0.95
                                              area=medium
                                                            maxDets=100
                                                                           = 0.013
                          ۵Ī
 Average Recall
                     (AR)
                             IoU=0.50:0.95
                                              area= large
                                                            maxDets=100
                                                                           = 0.123
```

- 解决2:有一些python数据流没有被记录而作为常量, 需要根据warning, 修改一些已知的变量, 如(代码)
- 问题3:onnx转trt时节点类型不支持

- 解决3:修改onnx图,插入一些类型转换节点。代码
- 问题4:onnx转trt时牛成模型显存不足
- 解决4:更新至TensorRT8.4.1.5可以直接生成模型,同时插入plugin也可以使模型成功生成。
- 问题5: 生成的TensorRT动态宽高模型推理出现nan
- 解决5: 修改python代码
- 问题5:行-列分离注意力RCDA(row column decoupled attention)的高效实现

```
[05/26/2022-14:28:46] [TRT] [W] Skipping tactic 0 due to insuficient memory on requested size of 644612864 detected for tactic 0.
[05/26/2022-14:28:46] [TRT] [E] 10: [optimizer.cpp::computeCosts::2011] Error Code 10: Internal Error (Could not find any implementation for node {ForeignNode[2123...Sigmoid_88 72]}.)
[05/26/2022-14:28:46] [TRT] [E] 2: [builder.cpp::buildSerializedNetwork::609] Error Code 2: Internal Error (Assertion enginePtr != nullptr failed. )
[!] Invalid Engine. Please ensure the engine was built correctly
```

● 解决5:尝试将里面除MatMul外的其他操作写成Plugin

优化过程

以下实验数据均在NVIDIA A10服务器上测试, TensorRT版本为8.4.1.5。

精度测试脚本为得为inference_trt_dynamic_shape.sh, baseline精度为44.263%mAP。


性能测试采用trtexec, 形状与精度测试的动态形状一致, 最小形状为320x512, 最大形状为1344x1344, 最优形状为800x800。

TRT自动优化


以TF32模式TensorRT自动优化作为基准, 测的latency=46.2253ms, throughtput=22.3029 qps, mAP=8.686% (采用A10+TensorRT8.4.1.5生成的模型精度有问题, 而采用RTX3090+TensorRT8.2.2生成的模型精度没有问题, 已提交bug)

插入Masked Softmax Plugin

优化前(latency=46.2253ms, throughtput=22.3029qps, mAP=8.686%): 从图中可以看到, myelin合并了许多操作在一起, 导致copyPackedKernel占比很大, 占27.2%, 其中MaxSubExpResSumDiv代表Softmax操作, 而这里的Softmax是带mask的, 因此可以自定义一个Masked Softmax Plugin来代替这些算子。



 优化后(latency=39.5283ms, throughtput=26.5501qps, mAP=44.270%): 插入Masked Softmax Plugin后, 精度正常。copyPackedKernel占比下降到4.4%, masked_softmax算子占比2.0%, 提速19.04%。





开启FP16模式

- 优化前(latency=39.5283ms, throughtput=26.5501qps, mAP=44.270%): 开启fp16是收益较大的, 只需要几行命令, 同时使算子也支持FP16就可以提速。
- 优化后(latency=18.0688ms, throughtput=57.9584qps, mAP=43.977%): 开启fp16后, mAP下降0.293%, 提速118.30%。


优化Tile 节点

• 优化前(latency=18.0688ms, throughtput=57.9584qps, mAP=43.977%): 从图中可以看到naiveSlice占了总推理时间3.1%, 其对应着Tile算子, 而实际上每次推理AnchorDETR这些算子都在重复计算, 它们的结果都是同一个, 叫posemb, 因此可以优化掉重复的Tile节点。同理posemb1d, posemb2d也可以被优化掉。







• 优化后(latency=17.3054ms, throughtput=59.1553qps, mAP=43.977%):naiveSlice的占比下降到0.6%, 提速2.07%。




合并参数

• 优化前(latency=17.3054ms, throughtput=59.1553qps, mAP=43.977%):Nsight system展示了许多copyPacke操作, 总共占比10.6%, 其中就有许多是合并Slice和Transpose获取权重和偏置的操作, 对应RCDA代码。通过slice操作获得的参数, 实际可以提前计算得到, 从而减少计算。






 优化后(latency=16.7689ms, throughtput=62.9635qps, mAP=43.938%): copyPacke操作占比下降到4.6%, 提速6.44%。剩余的copyPacke操作则是Transpose+Reshape的合并。




插入LayerNorm Plugin

• 优化前(latency=16.7689ms, throughtput=62.9635qps, mAP=43.938%):LayerNorm操作实际上由多个小算子组合而成, 导致不断luanch内核带来开销, 因此我们插入LayerNorm Plugin, 代替这些小算子。





• 优化后(latency=16.5521ms, throughtput=67.0348qps, mAP=43.891%):最终LayerNormPlugin操作占比 1.0%, 提速6.47%。




插入AddBiasTranspose Plugin

• 优化前(latency=16.5521ms, throughtput=67.0348qps, mAP=43.891%):RCDA里面, q_row和q_col分别要进行Add Bias, Transpose, Mul, Reshape, Transpose操作。这些操作可以写成一个Plugin。






• 优化后(latency=15.7594ms, throughtput=69.0925qps, mAP=43.920%):插入Plugin后,提速3.07%。




插入Mask2Pos Plugin

优化前(latency=15.7594ms, throughtput=69.0925qps, mAP=43.920%): TRT将mask2pos以及pos2posemb1d融合成了一个ForeignNode, 这里也可以自己实现一个Plugin进行替换。



• 优化后(latency=15.3353ms, throughtput=70.4344qps, mAP=43.934%):优化后的ForeignNode, 大部分都是内存的操作, 最终提速1.94%。



精度与加速效果

- 精度 最终优化模型在COCO2017验证集上的mAP=43.934%, 原始pytorch版本mAP=44.263%, 相比之下, mAP下降0.329%。

Method	Latency(ms)	Throughtput(qps)	mAP(%)
TRT-TF32	46.2253	22.3029	8.686
+MaskedSoftmax Plugin	39.5283	26.5501	44.270
+FP16	18.0688	57.9584	43.977
+opt-naiveSlice	17.3054	59.1553	43.977
+merge-parameters	16.7689	62.9635	43.938
+Layernorm Plugin	16.5521	67.0348	43.891
+AddBiasTranspose Plugin	15.7594	69.0925	43.920
+Mask2Pos Plugin	15.3353	70.4344	43.934